

**МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
імені ІГОРЯ СІКОРСЬКОГО»
Факультет інформатики та обчислювальної техніки**

КАФЕДРА ОБЧИСЛЮВАЛЬНОЇ ТЕХНІКИ

**МЕТОДИЧНІ ВКАЗІВКИ
ДО ВИКОНАННЯ ЛАБОРАТОРНИХ РОБІТ
З ДИСЦИПЛІНИ «ОСНОВИ НАУКИ ПРО ДАНІ»**
(для студентів спеціальності 121 Інженерія програмного забезпечення)
(для студентів спеціальності 123 Комп'ютерна інженерія) (для
студентів спеціальності 126 Інформаційні системи та технології)

підготовки бакалавр
назва освітньо-кваліфікаційного рівня

Ухвалено
на засіданні кафедри ОТ
протокол №18 від 24.06.2026

Погоджено
на засіданні методичної
комісії
протокол №12 26.06.2026

УДК 681.3.06

Методичні вказівки до виконання лабораторних робіт з
дисципліни
«Основи науки про дані» (для студентів спеціальності "Інженерія програмного
забезпечення"). /Укл.: Новотарський М. А.: НТУУ «КПІ» – 2026, 136 с.

Методичні вказівки до виконання лабораторних робіт з
дисципліни
«Основи науки про дані» містять завдання до лабораторних робіт. До кожної
роботи наведено методичні рекомендації з теорії, яка використовується
при виконанні лабораторних робіт, приведені деякі алгоритми
вирішення
завдань, вимоги до виконання роботи, індивідуальні завдання та контрольні
запитання.

Укладач: проф. Новотарський М.А.

Рецензент: проф. Стіренко С.Г.

Вступ
до лабораторних робіт з курсу
«Основи науки про дані»

Лабораторні роботи з даного курсу призначені отримання навичок практичного застосування методів добування даних, заснованих використанні бібліотек NumPy, Matplotlib, Pandas і PyTorch, TensorFlow, PyTensor. Важливо послідовно виконувати дані лабораторні роботи, оскільки кожна наступна лабораторна робота використовує навички роботи з бібліотеками, які отримані при виконанні попередньої лабораторної роботи. До кожного завдання додається відповідний зошит jupyter notebook.

Дані лабораторні роботи виконують шляхом модифікації початкових даних, які знаходяться у зошиті, номер якого відповідає номеру лабораторної роботи. Тому необхідно попередньо створити папку та завантажити в цю папку всі початкові зошити. Нуобхідно також уміти створити оригінальні зошитів jupyter notebook.

Для успішного захисту лаборатоних робіт разом зі звітами викладачеві необхідно надати зошити з виконними завданнями для кожної лаборатоної роботи. Звти та зошити jupyter notebook необхідно завантажувати у відповідне завдання, яке створене для вас у системі Google classroom. Перевірка теоретичних знань проводиться персонально виключно на заняттях з

лабораторних робіт у режимі відеоконференції.

ГРАФІК ПЕРЕВІРКИ ТЕОРІЇ

№	Назва лабораторної роботи	Дати прийому теорії
1	Лабораторна робота №1	09.09.26 - 23.09.26
2	Лабораторна робота №2	23.10.26 - 07.10.26
3	Лабораторна робота №3	07.10.26 - 04.11.26
4	Лабораторна робота №4	04.11.26 - 25.11.26
	Лабораторна робота №5	25.11.26-09.12.26

3

Лабораторна робота № 1

Підсумкові функції та відображення

Мета лабораторної роботи: навчитися вибрати відповідні дані з `DataFrame` або `Series`, вибирати правильні дані з набору даних.

Практична реалізація: відпрацювати операції переформатування даних для отримання необхідної структури набору даних.

Теоретичні відомості

Для виконання операцій переформатування даних використаємо набір даних з журналу про вина. Приклади коду наведені в Jupyter notebook з назвою `DD_lab1.ipynb`

На першому етапі імпортуємо бібліотеку `pandas` та модуль `NumPy`.

Наступним кроком завантажуюмо набір даних: `alcohol.csv`

Застосування підсумкових функцій

`Pandas` містить велику кількість простих "підсумкових функцій" (така назва не є офіційною), які перетворюють дані та представляють їх у зручному вигляді.

1. **Метод `describe()`**. Даний метод генерує підсумкові дані високого рівня для атрибутів вибраного стовпця. Результати виводу у даному методі

змінюються залежно від типу вхідного стовпця. Різні виводи даних можна побачити на прикладі виводу підсумків по стовпцю «points» та по стовпцю «country» в файлі `DD_lab1.ipynb`.

2. **Метод `mean()`** визначає середнє значення по числовому стовпцю. Метод застосовний тільки до числових стовпців.

3. **Метод `unique()`**. Для виводу тільки унікальних елементів даних у стовпці застосовуємо метод `unique()`. Цей метод можна застосовувати як до числових, так і до рядкових типів даних.

4. **Метод `value_counts()`**. Щоб вивести список унікальних значень і визначити, як часто вони трапляються в наборі даних, використовуємо метод `value_counts()`:

4

Застосування відображень

Відображення – це математичний термін, який позначає властивість функції приймати певний набір значень і "відображати" його на інший набір значень. При вирішенні задач з добування даних часто виникає потреба у створенні нових представлень на основі існуючих даних або в перетворенні даних з формату, в якому вони знаходиться зараз, у формат, який ми хочемо мати в подальшому. Відображення виконують цю функціональність. Розглянемо два основних методи для виконання відображень.

1. **Метод `map()`** є першим і дещо простішим. Він дозволяє застосувати відображення до кожного елемента стовпця. На прикладі застосування цього методу змінено шкалу оцінок вин. За нульове значення вибрано середнє значення оцінки, а всі інші оцінки перераховано відносно цього значення. Функція, яку ви передаєте `map()`, повинна очікувати одне значення від `Series` (значення стовпця «points», у наведеному вище прикладі) і повернути трансформовану версію цього значення. `map()` повертає нову серію, де всі значення були перетворені даною функцією.

2. **Метод `apply()`**. Цей метод використовуємо, якщо необхідно перетворити весь набір даних `DataFrame` шляхом виклику власного методу у кожному рядку. В наведеному прикладі ми виконали ті ж перетворення, що і в попередньому випадку та перерахували ціни на вина зі зростанням на 20%. В результаті отримали `DataFrame` зі зміненими даними.

Якщо у параметрах методу `reviews.apply()` вказати `axis = 'index'`, то замість передачі функції рядків нам потрібно задати функцію для перетворення кожного стовпця.

Отже, метод `map()` повертає перетворений новий набір даних `Series`, а метод `apply()` повертає новий `DataFrame`, відповідно. Вони не змінюють вихідні дані, за якими їх викликають. Якщо ми подивимось на початок нашого набору `reviews`, то побачимо, що він залишився без змін.

Вбудовані операції над стовпцями

1. Операція між елементами стовпця та константою

Замінімо метод `map()` вбудованою операцією, яка виконує ті ж дії, але швидше. У цьому коді ми виконуємо операцію між значеннями стовпця ліворуч (`Series`) та одним значенням праворуч (середнє значення). Бібліотека `Pandas` розглядає цей вираз і з'ясовує, що ми маємо на увазі відняти середнє значення від кожного значення в наборі даних.

2. Операція між двома стовпцями однакової довжини

5

Дана операція дозволяє виконати операція між двома наборами `Series` однакової довжини поелементно.

Такі операції швидші, ніж `map()` або `apply()`, оскільки вони використовують вбудовані в бібліотеку `Pandas` прискорення. Усі стандартні оператори `Python` (`>`, `<`, `==` тощо) працюють таким чином.

Однак вони не настільки гнучкі, як `map()` або `apply()`, які можуть робити більш просунуті речі, наприклад, застосовувати умовну логіку, що неможливо зробити лише додаванням і відніманням.

Зауваження

Матеріал даної лабораторної роботи підготовлено на основі матеріалів сайту <https://www.kaggle.com/>, який є одним з найпопулярніших сайтів для навчання у сфері `DataScience`. У своїй роботі ви можете використовувати будь-які матеріали з даного сайту за винятком набору даних, який використано в даній лабораторній роботі.

Завдання до лабораторної роботи № 1

1. Детально розглянути наведені теоретичні відомості до даної лабораторної роботи.
2. Ознайомитися з кодом, що наведений у `Jupyter notebook`

DD_lab1.ipynb.

3. Виберіть підходящий до завдання набір даних з сайту <https://www.kaggle.com/>
4. Застосувати до вибраного набору всі підсумкові функції та методи відображень, які розглянуті у теоретичних відомостях до лабораторної роботи.
5. Результат виконання лабораторної роботи має містити:

А) Звіт про виконання лабораторної роботи.

Звіт обов'язково має містити обґрунтоване пояснення дій щодо конкретних результатів роботи підсумкових функцій та відображень.

Склад звіту:

1. Титул
2. Тема
3. Мета
4. Короткі теоретичні відомості
5. Опис роботи з ДОДАВАННЯМ скріншотів
6. Висновок.

Б) Jupyter notebook файл з кодом та результатами обробки даних.

6

Лабораторна робота № 2

Індексування, вибір, редагування набору даних

Мета лабораторної роботи: навчитися швидко та ефективно вибирати необхідні дані з набору даних з використанням структур даних та інструментів бібліотеки Pandas.

Практична реалізація: набути практичних навичок вибору даних з структур Sources та DataFrame.

Теоретичні відомості

Використаємо набір даних, який містить дані про книги, які увійшли в топ продажів у інтернет-магазині Amazon. Приклади коду наведені в Jupyter notebook з назвою DD_lab2.ipynb

1. Імпортуємо бібліотеку Pandas.

```
>>>import pandas as pd
```

2. Читаємо набір даних amazon.csv

```
>>>book_dat = pd.read_csv("amazon.csv")  
Name Author User Rating Reviews Price Year Genre
```

0	10-Day Green Smoothie Cleanse	JJ Smith	4.7	17350	8	2016	Non Fiction
1	11/22/63: A Novel	Stephen King	4.6	2052	22	2011	Fiction
		Jordan B. Peterson	4.7	18979	15	2018	Non Fiction
2	12 Rules for Life: An Antidote to Chaos						
3	1984 (Signet Classics)	George Orwell	4.7	21424	6	2017	Fiction
		National Geographic Kids	4.8	7665	12	2019	Non Fiction
4	5,000 Awesome Facts (About Everything!) (Natio...						
...	...						
545	Wrecking Ball (Diary of a Wimpy Kid Book 14)	Doubting Your Gr... Jeff Kinney	4.9	9413	8	2019	Fiction
546	You Are a Badass: How to Stop Doubting Your Gr...						
547	You Are a Badass: How to Stop Doubting Your Gr...	Jen Sincero	4.7	14331	8	2016	Non Fiction
		Jen Sincero	4.7	14331	8	2017	Non Fiction
548	You Are a Badass: How to Stop Doubting Your Gr...	Jen Sincero	4.7	14331	8	2018	Non Fiction
		Jen Sincero	4.7	14331	8	2019	Non Fiction
549	You Are a Badass: How to Stop						

7

1. Вбудовані способи доступу

A) Доступ до стовпця можна забезпечити шляхом застосування його назви як атрибуту об'єкта з точковою нотацією.

```
>>>book_dat.Name
0 10-Day Green Smoothie Cleanse
1 11/22/63: A Novel
2 12 Rules for Life: An Antidote to Chaos
3 1984 (Signet Classics)
4 5,000 Awesome Facts (About Everything!) (Natio...
...
545 Wrecking Ball (Diary of a Wimpy Kid Book 14)
546 You Are a Badass: How to Stop Doubting Your Gr...
547 You Are a Badass: How to Stop Doubting Your Gr...
548 You Are a Badass: How to Stop Doubting Your Gr...
549 You Are a Badass: How to Stop Doubting Your Gr...
Name: Name, Length: 550, dtype: object
```

B) Доступ до стовпця як до елемента словника. У цьому випадку ключом словника є назва стовпця, а значенням – Series стовпця.

```
>>>book_dat['Name']
0 10-Day Green Smoothie Cleanse
1 11/22/63: A Novel
2 12 Rules for Life: An Antidote to Chaos
3 1984 (Signet Classics)
4 5,000 Awesome Facts (About Everything!) (Natio...
...
545 Wrecking Ball (Diary of a Wimpy Kid Book 14)
```

```
546 You Are a Badass: How to Stop Doubting Your Gr...
547 You Are a Badass: How to Stop Doubting Your Gr...
548 You Are a Badass: How to Stop Doubting Your Gr...
549 You Are a Badass: How to Stop Doubting Your Gr...
Name: Name, Length: 550, dtype: object
```

С) Доступ до елемента вибраного стовпця по індексу

```
>>>book_dat['Name'][3]
'1984 (Signet Classics)'
```

2. Індексно-орієнтований вибір у бібліотеці Pandas У бібліотеці Pandas є власні оператори доступу, `loc` та `iloc`. Ці оператори використовуються для більш просунутих операцій. В роботі бажано використовувати саме ці оператори.

А) Вибір рядка на основі індексу

```
>>>book_dat.iloc[0]
Name 10-Day Green Smoothie Cleanse
Author JJ Smith
User Rating 4.7
Reviews 17350
Price 8
Year 2016
Genre Non Fiction
```

8

```
Name: 0, dtype: object
```

Б) Вибір стовпця на основі індексу

```
>>>book_dat.iloc[:, 1]
0 JJ Smith
1 Stephen King
2 Jordan B. Peterson
3 George Orwell
4 National Geographic Kids
...
545 Jeff Kinney
546 Jen Sincero
547 Jen Sincero
548 Jen Sincero
549 Jen Sincero
Name: Author, Length: 550, dtype: object
```

В) Вибір стовпця на основі індексу з одночасною операцією зрізу з елементів стовпця в Series.

```
>>>book_dat.iloc[:3, 1]
0 JJ Smith
1 Stephen King
2 Jordan B. Peterson
```

```
Name: Author, dtype: object
```

```
>>>book_dat.iloc[1:4, 1]
```

```
1 Stephen King
2 Jordan B. Peterson
3 George Orwell
Name: Author, dtype: object
```

```
>>>book_dat.iloc[1:5:2, 1]
```

```
1 Stephen King
3 George Orwell
Name: Author, dtype: object
```

Г) Вибір зрізу рядків

```
>>>book_dat.iloc[:4]
```

```
Name Author User Rating Reviews Price Year Genre 0 10-Day Green
Smoothie Cleanse JJ Smith 4.7 17350 8 2016 Non Fiction
1 11/22/63: A Novel Stephen King 4.6 2052 22 2011 Fiction
2 12 Rules for Life: An Antidote to Chaos Jordan B. Peterson 4.7 18979
15 2018 Non Fiction
3 1984 (Signet Classics) George Orwell 4.7 21424 6 2017 Fiction
```

Д) Вибір зрізу рядків з кінця набору даних з використанням від'ємного індексу

9

```
>>>book_dat.iloc[-4:]
```

```
Name Author User Rating Reviews Price Year Genre 546 You Are a
Badass: How to Stop Doubting Your Gr... Jen Sincero 4.7 14331 8 2016 Non
Fiction
547 You Are a Badass: How to Stop Doubting Your Gr... Jen Sincero 4.7
14331 8 2017 Non Fiction
548 You Are a Badass: How to Stop Doubting Your Gr... Jen Sincero 4.7
14331 8 2018 Non Fiction
549 You Are a Badass: How to Stop Doubting Your Gr... Jen Sincero 4.7
14331 8 2019 Non Fiction
```

3. Мітко-орієнтований вибір в бібліотеці Pandas

Для виконання мітко-орієнтованого вибору застосовують метод `loc`.

А) Вибір по індексу елементу стовпця заданого по імені.

```
>>>book_dat.loc[0, 'Name']
'10-Day Green Smoothie Cleanse'
```

Б) Вибір підмножини стовпців, імена яких задані списком

```
>>>book_dat.loc[:, ['Author', 'Price', 'Year']]
Author Price Year
0 JJ Smith 8 2016
```

```

1 Stephen King 22 2011
2 Jordan B. Peterson 15 2018
3 George Orwell 6 2017
4 National Geographic Kids 12 2019
... ..
545 Jeff Kinney 8 2019
546 Jen Sincero 8 2016
547 Jen Sincero 8 2017
548 Jen Sincero 8 2018
549 Jen Sincero 8 2019

```

В) Вибір перших 6 рядків з підмножини стовпців, імена яких задані списком

```

>>>book_dat.loc[:5, ['Author','Price', 'Year']]

Author Price Year
0 JJ Smith 8 2016
1 Stephen King 22 2011
2 Jordan B. Peterson 15 2018
3 George Orwell 6 2017
4 National Geographic Kids 12 2019
5 George R. R. Martin 11 2011

```

Г) Вибір рядків з кроком у заданому діапазоні з підмножини стовпців, імена яких задані списком

```

>>>book_dat.loc[1:100:11, ['Author','Price', 'Year']]

```

10

```

Author Price Year
1 Stephen King 22 2011
12 Jaycee Dugard 32 2011
23 Chris Kyle 9 2015
34 Atul Gawande 15 2015
45 Thomas Piketty 28 2014
56 Abraham Verghese 11 2010
67 George W. Bush 17 2010
78 Zhi Gang Sha 6 2009
89 Marty Noble 5 2015
100 Ray Bradbury 8 2016

```

4. Маніпулювання індексом

Важливо відмітити, що індекс, який ми використовуємо, не є незмінним. Ми можемо маніпулювати індексом у будь-який спосіб, який вважаємо за потрібне.

Для виконання таких маніпуляцій можна використовувати метод `set_index()` до першого стовпця «Name».

Це корисно, якщо ми можемо створити індекс для набору даних, який кращий за поточний.

```
>>>book_dat.set_index("Name")
```

Name	Author	User Rating	Reviews	Price	Year	Genre
10-Day Green Smoothie Cleanse		4.6	2052	22	2011	Fiction
11/22/63: A Novel						
JJ Smith	4.7	17350	8	2016		Non Fiction
12 Rules for Life: An Antidote to Chaos	Geographic Kids)	4.7	18979	15	2018	Non Fiction
1984 (Signet Classics)	Jordan B. Peterson					
5,000 Awesome Facts (About Everything!)	George Orwell	4.7	21424	6	2017	Fiction
(National Geographic Kids	National Geographic Kids					
... ..						
Wrecking Ball (Diary of a Wimpy Kid Book 14)		14331	8	2016		Non Fiction
You Are a Badass: How to Stop Doubting Your Greatness and Start Living an Awesome Life						
You Are a Badass: How to Stop Doubting Your						
Jeff Kinney	4.9	9413	8	2019	Fiction	Jen Sincero 4.7
						Jen Sincero 4.7 14331 8 2017 Non Fiction

11

Author	User Rating	Reviews	Price	Year	Genre	Greatness and
Start Living an Awesome Life						
You Are a Badass: How to Stop Doubting Your Greatness and Start Living an Awesome Life	Jen Sincero	4.7	14331	8	2019	Non Fiction
You Are a Badass: How to Stop Doubting Your Greatness and Start Living an Awesome Life						
You Are a Badass: How to Stop Doubting Your Greatness and Start Living an Awesome Life						
Jen Sincero	4.7	14331	8	2018		Non Fiction

4. Умовний вибір

Розглянемо вибір елементів набору даних, виходячи з у

МОВИ А) Проста умова

Наприклад, ми хочемо сформувати піднабір даних, який складається з книг, ціна яких є більшою за середню ціну.

```
>>>pmean=book_dat.Price.mean()
>>>print("Середня ціна =",pmean)
>>>book_dat.loc[book_dat.Price>pmean]
```

Середня ціна = 13.1

	Name	Author	User	Rating	Reviews	Price	Year	Genre
1	11/22/63: A Novel	Stephen King	4.6	2052	22	2011	Fiction	
2	12 Rules for Life: An Antidote to Chaos	A Game of Thrones / A Clash of Kings / A Storm... Jordan B. Peterson	George R. R. Martin	4.7	18979	15	2018	Non Fiction
6			4.7	19735	30	2014	Fiction	
7	A Gentleman in Moscow: A Novel	Amor Towles	4.7	19699	15	2017	Fiction	
12	A Stolen Life: A Memoir	Jaycee Dugard	4.6	4149	32	2011	Non Fiction	
...	...	...	...	...	...	...	...	...
528	What Pet Should I Get? (Classic	Seuss)	Dr. Seuss	4.7	1873	14	2015	Fiction
533	When Breath Becomes Air	Paul Kalanithi	4.8	13779	14	2016	Non Fiction	
534	Where the Crawdads Sing	Delia Owens	4.8	87841	15	2019	Fiction	
					12			
537	Wild: From Lost to Found on the Pacific Crest ...	Cheryl Strayed	4.4	17044	18	2012	Non Fiction	
538	Winter of the World: Book Two of the Century T...	Ken Follett	4.5	10760	15	2012	Fiction	

Б) Складна умова

Складна умова дозволяє виконувати логічні операції вибору з використанням логічних операторів «&» та «|».

```
>>>pmean=book_dat.Price.mean()
>>>print("Середня ціна =",pmean)
>>>book_dat.loc[(book_dat.Price<pmean) & (book_dat.Year==2018)]
```

Середня ціна = 13.1

Name	Author	User	Rating	Reviews	Price	Year	Genre
------	--------	------	--------	---------	-------	------	-------

	James Comey	4.7	5983	3	2018	Non Fiction
8	A Higher Loyalty: Truth, Lies, and Leadership	Madeleine L'Engle	4.5	5153	5	2018 Fiction
13	A Wrinkle in Time (Time Quintet)					
32	Becoming Michelle Obama		4.8	61133	11	2018 Non Fiction
53	Crazy Rich Asians (Crazy Rich Asians Trilogy)	Kevin Kwan	4.3	6143	8	2018 Fiction
66	Dear Zoo: A Lift-the-Flap Book	Rod Campbell	4.8	10922	5	2018 Fiction
81	Dog Man and Cat Kid: From the Creator of Capta...			7235	4	2018 Fiction Dav Pilkey 4.9 5470 6 2018
83	Dog Man: Brawl of the Wild: From the Creator o...					Fiction
87	Dog Man: Lord of the Fleas: From the Creator o...					
	Dav Pilkey	4.9	5062	6	2018 Fiction Dav Pilkey	4.9
101	Fahrenheit 451	Ray Bradbury	4.6	10721	8	2018 Fiction
103	Fear: Trump in the White House	Bob Woodward	4.4	6042	2	2018 Non Fiction
109	Fire and Fury: Inside the Trump White House	Michael Wolff	4.2	13677	6	2018 Non Fiction
114	First 100 Words	Roger Priddy	4.7	17323	4	2018 Non Fiction
126	Giraffes Can't Dance	Giles Andreae	4.8	14038	4	2018 Fiction
129	Girl, Wash Your Face: Stop Believing the Lies ...	Rachel Hollis	4.6	22288	12	2018 Non Fiction

13

Name	Author	User	Rating	Reviews	Price	Year	Genre
	Jennifer Smith		4.4	7396	13	2018	Non Fiction
144	Goodnight Moon	Margaret Wise Brown	4.8	8837	5	2018	Fiction
	Anthony Bourdain		4.8	2507	8	2018	Non Fiction
	Jill Twiss		4.9	11881	13	2018	Fiction
170	How to Win Friends & Influence People						
185	Instant Pot Pressure Cooker Cookbook: 500 Ever...						
203	Kitchen Confidential Updated Edition: Adventur...						
207	Last Week Tonight with John Oliver Presents A ...						
215	Lettering and Modern Calligraphy: A Beginner's...						
	Dale Carnegie	4.7	25001	11	2018	Non Fiction	
	Paper Peony Press	4.4	7550	6	2018	Non Fiction	
220	Little Fires Everywhere	Celeste Ng	4.5	25706	12	2018	Fiction
231	Milk and Honey	Rupi Kaur	4.7	17739	8	2018	Non Fiction
251	Oh, the Places You'll Go!	Dr. Seuss	4.9	21834	8	2018	Fiction

262 P is for Potty! (Sesame Street) (Lift-the-Flap)	Naomi Kleinberg 4.7 10820 5 2018 Non Fiction
287 Ready Player One: A Novel Ernest Cline 4.6 22536 12 2018 Fiction	
293 School Zone - Big Preschool Workbook - Ages 4 ...	School Zone 4.8 23047 6 2018 Non Fiction
328 The 5 Love Languages: The Secret to Love that ...	Gary Chapman 4.8 25554 8 2018 Non Fiction
355 The Complete Ketogenic Diet for Beginners: You...	Amy Ramos 4.3 13061 6 2018 Non Fiction
379 The Four Agreements: A Practical Guide to Pers...	Don Miguel Ruiz 4.7 23308 6 2018 Non Fiction
401 The Hate U Give Angie Thomas 4.8 9947 11 2018 Fiction	
416 The Instant Pot Electric Pressure Cooker Cookb...	Laurel Randolph 4.3 7368 7 2018 Non Fiction
435 The Meltdown (Diary of a Wimpy Kid Book 13)	Jeff Kinney 4.8 5898 8 2018 Fiction
452 The Pout-Pout Fish Deborah Diesen 4.8 9784 5 2018 Fiction	481 The Very Hungry Caterpillar Eric Carle 4.9 19546 5 2018 Fiction
488 The Wonderful Things You Will Be	Emily Winfield Martin 4.9 8842 10 2018 Fiction
490 The Wonky Donkey Craig Smith 4.8 30183 4 2018 Fiction	

14

Name	Author	User Rating	Reviews	Price	Year	Genre
Comments That Don't ...		4.6	6669	12	2018	Non Fiction
The Staff of The Late Show with						
536 Whose Boat Is This Boat?:	Jen Sincero	4.7	14331	8	2018	Non Fiction
548 You Are a Badass: How to Stop Doubting Your Gr...						

В) Умовні селектори

«is in» – дозволяє вибирати дані, значення яких є у списку значень. Наприклад, ось як ми можемо використовувати його для вибору книг, автором яких є Jen Sincero.

```
>>>book_dat.loc[book_dat.Author.isin(['Jen Sincero'])]
      Name Author User Rating      Reviews Price Year Genre
      You Are a Badass: How to Stop Dou
      bting Your Gr...      549
546      You Are a Badass: How to Stop Dou
      bting Your Gr...      548
      You Are a Badass: How to Stop Dou Jen
      bting Your Gr...      Sincero
547
```

Jen	Jen	4.7 14331 8 2018 Non Fiction
Sincero	Sincero	4.7 14331 8 2019 Non Fiction
Jen	4.7 14331 8 2016 Non Fiction	
Sincero	4.7 14331 8 2017 Non Fiction	

Додаючи елементи до списку, можемо вибрати кілька елементів одночасно. Наприклад, вибираємо публікації 2016 та 2017 років.

```
>>>book_dat.loc[book_dat.Year.isin([2016,2017])]
```

	Name	Author	User	Rating	Reviews	Price	Year	Genre
0	10-Day Green Smoothie Cleanse	JJ Smith	4.7	17350	8	2016	Non Fiction	
3	1984 (Signet Classics)	George Orwell				4.7	21424	6 2017 Fiction
7	A Gentleman in Moscow: A Novel	Amor Towles	4.7	19699	15	2017	Fiction	
9	A Man Called Ove: A Novel	Fredrik Backman						
10	A Man Called Ove: A Novel	Fredrik Backman	4.6	23848	8	2016	Fiction	4.6 23848 8 2017
...	...	...	...	...	...	...	...	...

15

	Name	Author	User	Rating	Reviews	Price	Year	Genre
533	When Breath Becomes Air	Paul Kalanithi	4.8	13779	14	2016	Non Fiction	
543	Wonder	R. J. Palacio	4.8	21625	9	2016	Fiction	544 Wonder R. J. Palacio 4.8 21625 9 2017 Fiction
546	You Are a Badass: How to Stop							Doubting Your Gr...
	Doubting Your Gr...	Jen Sincero	4.7	14331	8	2016	Non Fiction	
547	You Are a Badass: How to Stop	Jen Sincero	4.7	14331	8	2017	Non Fiction	

«isnull» (або «notnull»). Ці методи дозволяють виділити значення, які є (або не є) порожніми (NaN).

```
>>>book_dat.loc[book_dat.Price.isnull()]
```

Name	Author	User	Rating	Reviews	Price	Year	Genre
------	--------	------	--------	---------	-------	------	-------

Очевидно, що у нашому наборі немає книг без ці

ни. 5. Редагування даних

Ми можемо присвоїти значення елементам DataFrame.

```
me. >>>book_dat['New'] = 'data'

>>>book_dat['New']

0 data
1 data
2 data
3 data
4 data
...
545 data
546 data
547 data
548 data
549 data
Name: New, Length: 550, dtype: object

>>>book_dat
```

	Name	Author	User	Rating		Reviews	Price	Year	Genre	New	
0	10-Day Green Smoothie	Cleanse			JJ Smith	4.7	17350	8	2016	Non Fiction	data

16

	Name	Author	User	Rating		Reviews	Price	Year	Genre	New
1	11/22/63: A Novel	Stephen King	4.6	2052	22	2011	Fiction	data		
2	12 Rules for Life: An Antidote to Chaos	Jordan B. Peterson							Fiction	
			4.7	18979	15	2018	Non	data		
3	1984 (Signet Classics)	George Orwell	4.7	21424	6	2017	Fiction	data		
4	ut Everything!) (National Geographic Kids								Fiction	
			4.8	7665	12	2019	Non	data		
5,000 Awesome Facts (Abo										
...	...	...	...	...	...	...	...	...	...	...
545	Wrecking Ball (Diary of a Wimpy Kid Book 14)	Jeff Kinney	4.9	9413	8	2019	Fiction	data		
		Stop Doubting Your Gr...								
546	You Are a Badass: How to Stop Doubting Your Gr...	Jen Sincero	4.7	14331	8	2018	Non Fiction			
547	You Are a Badass: How to Stop Doubting Your Gr...	Jen Sincero	4.7	14331	8	2016	Non Fiction			
548	You Are a Badass: How to	Jen Sincero	4.7	14331	8	2017	Non Fiction			

```
>>>book_dat['my_index'] = range(len(book_dat), 0, -1)
>>>book_dat['my_index']
```

```
>>>book_dat
```

	Name	Author	User	Rating	Reviews	Price	Year	Genre	New	my_index
				Smoothie Cleanse				Fiction		
10-Day Green		JJ Smith	4.7	17350	8	2016	Non	data	550	

	Name	Author	User	Rating	Reviews	Price	Year	Genre	New	my_index
		Antidote to Chaos		4.7	18979	15	2018	Non	data	548
2	12 Rules for Life: An	Jordan B. Peterson		Fiction						
3	1984 (Signet Classics)	George Orwell		4.7	21424	6	2017	Fiction	data	547
4	5,000 Awesome Facts (About Everything!)	(Natio... National			Geographic	Kids		Fiction		
				4.8	7665	12	2019	Non	data	546

546	You Are a Badass: How to Stop Doubting Your Gr...	548	You Are a Badass: How to Stop Doubting Your Gr...	Зауваження
				Jen Sincero 4.7 14331 8 2016 Non Fiction
547	You Are a Badass: How to Stop Doubting Your Gr...	549	You Are a Badass: How to Stop Doubting Your Gr...	
				Jen Sincero 4.7 14331 8 2017 Non Fiction

Jen Sincero 4.7 14331 8 2018 Non Jen Sincero 4.7 14331 8 2019 Non
Fiction Fiction

Матеріал даної лабораторної роботи підготовлено на основі матеріалів сайту <https://www.kaggle.com/>, який є одним з найпопулярніших сайтів для навчання у сфері DataScience. У своїй роботі ви можете використовувати будь-які матеріали з даного сайту за винятком набору даних, який використано в даній лабораторній роботі.

Завдання до лабораторної роботи № 2

6. Детально розглянути наведені теоретичні відомості до даної лабораторної роботи.
7. Ознайомитися з кодом, що наведений у Jupyter notebook `DD_lab2.ipynb`.
8. Застосувати до вибраного набору всі методи індексування, вибору та редагування набору даних.

18

9. Виберіть підходящий до завдання довільний набір даних з сайту <https://www.kaggle.com/>
10. Результат виконання лабораторної роботи має містити:

А) Звіт про виконання лабораторної роботи.

Звіт обов'язково має містити обґрунтоване пояснення конкретної дії методів індексування, вибору та редагування.

Склад звіту:

7. Титул
8. Тема
9. Мета
10. Короткі теоретичні відомості
11. Опис роботи з ДОДАВАННЯМ скріншотів
12. Висновок.

Б) Jupyter notebook файл з кодом та результатами обробки даних.

Лабораторна робота № 3

Робота з пропущеними даними

Мета лабораторної роботи: навчитися працювати з наборами даних, які містять відсутні або помилкові дані.

Практична реалізація: відпрацювати практичні підходи при роботі з реальними даними.

Теоретичні відомості

Використаємо набір даних про події, які відбувалися в іграх з американського футболу. Приклади коду наведені в Jupyter notebook з назвою `DD_lab3.ipynb`

На першому етапі імпортуємо всі необхідні для роботи бібліотеки.

Потім необхідно прочитати набір даних, над яким виконувати операції.
Назва даного набору даних: `football.csv`

Для подальшого аналізу даних необхідно забезпечити повторюваність експерименту. Тому задамо зерно генератора випадкових чисел.

Перший етап аналізу даних передбачає перше ознайомлення з даними з метою визначення елементів даних, які представлені як `NaN` або `None`.

Для цього просто виводимо перші 5 рядків, з яких можна зразу зробити висновок, що набір даних містить пропущені елементи.

Другий етап дозволяє визначити кількість відсутніх даних у кожному стовпці.

Ми отримали велику кількість відсутніх даних у деяких стовпцях. Визначимо, який відсоток значень у нашому наборі даних відсутній, щоб краще зрозуміти масштаб проблеми.

Після обчислення ми отримали, що відсутні майже 25% елементів

даних. **Третій етап.** Визначення причини відсутності елементів даних.

Не існує формалізованого алгоритму визначення відсутності даних. У цьому випадку необхідно опиратися на інтуїцію. Головне питання, яке необхідно прояснити собі на цьому етапі, полягає у тому, щоб відповісти на питання чи значення було пропущене з якихось причин (помилка, випадковість), чи елемент даних взагалі не існує.

1. Якщо елемент даних відсутній випадково, то виконуємо його імплементацію, тобто намагаємося здогадатися з аналізу наявних даних про його приблизне значення.

20

2. Якщо значення відсутнє за визначенням (наприклад, зріст старшого сина у людини, яка взагалі не має дітей), то дане значення слід залишити `NaN`.

Наприклад, у стовпці `TimeSecs` міститься інформація про кількість секунд, що залишилися в грі. Це означає, що ці значення, ймовірно, відсутні, оскільки вони не були занесені в набір даних, а не тому, що їх не існує. Отже, ми можемо виконати імплементацію цих даних.

У випадку ретельного аналізу даних необхідно визначити причини відсутності даних у кожному стовпці.

Четвертий етап. Обробка пропущених даних.

Існує підхід, який забезпечує заповнення даних, але вносить певний

шум.

1. Можна просто видалити всі стовпці або рядки, у яких знаходяться відсутні значення. (Цей підхід не рекомендується, оскільки може призвести до втрати важливої інформації)

В `DD_lab3.ipynb` показано роботу функції `dropna()`, яка реалізує даний підхід.

а) Спочатку видаляємо рядки з пропусками. Отримали пустий набір даних, оскільки у кожному рядку є відсутні елементи даних. б) Видаляємо стовпці з пропусками. Отримали 41 повністю заповнений стовпець.

2. Другий спосіб полягає у заповненні набору даних певним числом, яке вказується як параметр функції `fillna()`.

Якщо необхідно заповнити одним і тим самим значенням тільки частину набору даних, то необхідно спочатку сформувати піднабір даних.

3. Третій спосіб дозволяє заповнити відсутнє значення будь-яким значенням, яке йде безпосередньо після даного в тому ж стовпці. Це може актуалізувати наш набір даних, якщо він складається зі спостережень, що виконуються послідовно.

Зауваження

Матеріал даної лабораторної роботи підготовлено на основі матеріалів сайту <https://www.kaggle.com/>, який є одним з найпопулярніших сайтів для навчання у сфері DataScience. У своїй роботі ви можете використовувати будь-які матеріали з даного сайту за винятком набору даних, який використано в даній лабораторній роботі.

Завдання до лабораторної роботи №3

1. Детально розглянути наведені теоретичні відомості до даної лабораторної роботи.
2. Ознайомитися з кодом, що наведений у Jupyter notebook `DD_lab3.ipynb`.
3. Виберіть підходящий до завдання набір даних з сайту <https://www.kaggle.com/>.
4. Виконати етапи аналізу та попередньої обробки даних, наведені в даній лабораторній роботі.

5. Результат виконання лабораторної роботи має містити

А) Звіт про виконання лабораторної роботи.

Звіт обов'язково має містити обґрунтоване пояснення прийнятих рішень щодо вибору підходу до обробки відсутніх даних. **Склад звіту:**

13.Титул

14.Тема

15.Мета

16.Короткі теоретичні відомості

17.Опис роботи з ДОДАВАННЯМ скріншотів

18.Висновок.

Б) Jupyter notebook файл з кодом та результатами обробки даних.

В) Посилання на датасет у мережі Інтернет.

Лабораторна робота № 4

Розв'язування задачі лінійної регресії

Мета лабораторної роботи: навчитися працювати з простою моделлю лінійної регресії.

Практична реалізація: відпрацювати на реальних даних послідовність дій, які є необхідними для вирішення задачі лінійної регресії.

Теоретичні відомості

Використаємо набір даних про відвідувачів магазину. Приклади коду наведені в Jupyter notebook з назвою `DD_lab4.ipynb`

Імпортування бібліотек

```
# Модуль для підтримки алгебраїчних обчислень
>>>import numpy as np
# Бібліотека для обробки набору даних
>>>import pandas as pd
# Бібліотека для візуалізації даних
>>>import matplotlib.pyplot as plt
```

Завантаження набору даних

Читаємо набір даних, на якому будемо тренувати модель. Назва даного набору даних: `train.csv`

```
>>>mydata = pd.read_csv('linear_reg/train.csv')
```

Попередня перевірка набору даних

```
# початкові дані
>>>mydata.head()
```

	x	y
0	24.0	21.549452
1	50.0	47.464463
2	15.0	17.218656
3	38.0	36.586398
4	87.0	87.288984

```
# прикінцеві дані
>>>mydata.tail()
```

	x	y
695	58.0	58.595006
696	93.0	94.625094
697	82.0	88.603770
698	66.0	

		63.648685
699	97.0	94.975266

```
#перегляд розміру набору даних
>>>mydata.shape
(699, 2)
```

23

```
#перевірка повноти набору даних
>>>mydata.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 700 entries, 0 to 699
Data columns (total 2 columns):
 # Column Non-Null Count Dtype
---  ---
 0 x 700 non-null float64
 1 y 699 non-null float64
dtypes: float64(2)
memory usage: 11.1 KB
```

З отриманих результатів бачимо, що кількість елементів у стовпцях «x» та «y» відрізняється. Видалимо рядок, який містить значення NaN.

```
>>>mydata.dropna(inplace=True)

# повторна перевірка повноти набору даних
>>>mydata.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 699 entries, 0 to 699
Data columns (total 2 columns):
 # Column Non-Null Count Dtype
---  ---
 0 x 699 non-null float64
 1 y 699 non-null float64
dtypes: float64(2)
memory usage: 16.4 KB
```

Роздрукуємо графік тренувального набору даних.

```
>>>plt.scatter(mydata["x"],mydata["y"],s=10)
```

Переформуємо структуру даних mydata

```
>>>X = mydata["x"].values.reshape(-1,1)
>>>Y = mydata["y"].values.reshape(-1,1)
>>>mydata["x"].head(10)
```

```

0 24.0
1 50.0
2 15.0
3 38.0
4 87.0
5 36.0
6 12.0
7 81.0
8 25.0
9 5.0
Name: x, dtype: float64

```

```

>>>X[0:10]

array([[24.],

```

24

```

[50.],
[15.],
[38.],
[87.],
[36.],
[12.],
[81.],
[25.],
[ 5.]])

```

Навчання моделі

Набір даних `train` поділяється на тренувальні дані та дані перехресної перевірки.

```

>>>from sklearn.model_selection import train_test_split

>>>X_train,X_cv,y_train,y_cv=train_test_split(X,Y,test_size=0.3,random_state=143)

```

Навчання моделі лінійної регресії з використанням навчальних (тренувальних) даних

```

>>>from sklearn.linear_model import LinearRegression
>>>lin_reg = LinearRegression()
>>>lin_reg.fit(X_train,y_train)

```

Щоб перевірити успішність навчання, ми перевіряємо прогноз, використовуючи перші п'ять значень. Ми спостерігаємо, що передбачені значення майже збігаються з фактичними мітками.

```

>>>some_data = X_train[:5]
>>>some_labels = y_train[:5]
>>>print("Predictions: " ,lin_reg.predict(some_data))
>>>print("Labels:",some_labels)

```

```

Predictions: [[33.76440245]
[63.88885236]
[17.69802917]

```

```

[16.69388084]
[21.71462249]]
Labels: [[30.48882921]
[66.7346608 ]
[21.21321959]
[13.24991628]
[18.56241391]]

```

Перевіримо середньоквадратичну помилку

```

>>>from sklearn.metrics import mean_squared_error
>>>predictions = lin_reg.predict(X_train)
>>>mse = mean_squared_error(y_train, predictions)
>>>rmse = np.sqrt(mse)
>>>rmse

```

```

2.7396101133706083

```

25

Відобразимо червоною лінією отримані дані, а розсіяні дані показують результати крос-волідації.

```

>>>plt.scatter(X_train, y_train,s=10)
>>>plt.plot(X_train, predictions, color='red')
>>>plt.show()

```




Рис. 1. Результат навчання моделі лінійної регресії

Знайдемо середньоквадратичну помилку на даних крос-волідації.

```

>>>cv_predictions = lin_reg.predict(X_cv)
>>>cv_mse = mean_squared_error(y_cv, cv_predictions)
>>>cv_rmse = np.sqrt(cv_mse)
>>>cv_rmse

```

```

2.962299120833467

```

Імпортуємо тестовий набір даних і визначимо середньоквадратичну помилку при його використанні на даній регресійній моделі. >>>data_test = pd.read_csv("linear_reg/test.csv")
>>>X_test = mydata["x"].values.reshape(-1,1)
>>>y_test = mydata["y"].values.reshape(-1,1)

```
>>>final_predictions = lin_reg.predict(X_test)
>>>final_mse = mean_squared_error(y_test, final_predictions)
>>>final_rmse = np.sqrt(final_mse)
>>>final_rmse
```

2.8083686160906525

```
#Перевіряємо r2 score
>>>from sklearn.metrics import r2_score
>>>score=r2_score(y_test, final_predictions)
>>>score
```

0.9906788622737417

```
>>>plt.figure(figsize=(10.66,6))
>>>plt.scatter(mydata["x"],mydata["y"],s=10)
>>>plt.savefig("linear_reg/myresult.jpg")
```

26




Рис. 2. Дані з тестового набору

```
>>>plt.figure(figsize=(10.66,6))
>>>plt.scatter(mydata["x"],mydata["y"],s=10)
>>>plt.plot(X_train, predictions, color='red')
>>>plt.savefig("linear_reg/final_graph.jpg")
```




Рис. 3. Результат роботи моделі на тестовому наборі даних

Зауваження

Матеріал даної лабораторної роботи підготовлено на основі матеріалів сайту <https://www.kaggle.com/>, який є одним з найпопулярніших сайтів для навчання у сфері DataScience. У своїй роботі ви можете використовувати будь-які матеріали з даного сайту за винятком набору даних, який використано в даній лабораторній роботі.

Завдання до лабораторної роботи № 4

27

1. Детально розглянути наведені теоретичні відомості до даної лабораторної роботи.
2. Ознайомитися з кодом, що наведений у Jupyter notebook `DD_lab4.ipynb`.
3. Завантажити підходящий до завдання набір даних з сайту <https://www.kaggle.com/>
4. Вирішити задачу лінійної регресії, спираючись на приклад, який описаний у теоретичних відомостях та наведений у ноутбукі `DD_lab4.ipynb`.
5. Результат виконання лабораторної роботи має містити

А) Звіт про виконання лабораторної роботи.

Звіт обов'язково має містити обґрунтоване пояснення прийнятих рішень щодо послідовності попередньої обробки даних, застосованого методу лінійної регресії, візуалізації.

Склад звіту:

- 19.Титул
- 20.Тема
- 21.Мета
- 22.Короткі теоретичні відомості
- 23.Опис роботи з ДОДАВАННЯМ скріншотів
- 24.Висновок.

Б) Jupyter notebook файл з кодом та результатами обробки

даних.

В) Тренувальний та тестовий набори даних або посилання на них у мережі Інтернет.

28

Лабораторна робота № 5

Розв'язування задачі кластеризації

Методичні вказівки для виконання лабораторної роботи

Мета лабораторної роботи: навчитися працювати з простим алгоритмом кластеризації, який відносять до алгоритмів аналізу ринкового кошику.

Практична реалізація: відпрацювати на реальних даних алгоритм навчання без учителя (Алгоритм кластеризації k -середніх) у найпростішій формі.

Теоретичні відомості

Використаємо набір даних про відвідувачів магазину. Приклади коду наведені в Jupyter notebook з назвою `DD_lab5.ipynb`

Імпортування бібліотек

```
# Модуль для підтримки алгебраїчних обчислень
>>>import numpy as np
# Бібліотека для обробки набору даних
>>>import pandas as pd
# Бібліотеки для візуалізації даних
>>>import matplotlib.pyplot as plt
>>>import seaborn as sns
```

Завантаження набору даних

Читаємо набір даних, над яким будемо працювати. Назва даного набору даних: `shopping.csv`

```
>>>customer_set = pd.read_csv('shopping.csv')
```

Попередня перевірка набору даних

```
# початкові дані  
>>>customer_set.head()
```

	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)
0	1	Male	19	15	39
1	2	Male	21	15	81
2	3	Female	20	16	6
3	4	Female	23	16	77
4	5	Female	31	17	40

```
# прикінцеві дані  
>>>customer_set.tail()
```

	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)
195	196	Female	35	120	79
196	197	Female	45	126	28
197	198	Male	32	126	74

198	199		32	137	18
-----	-----	--	----	-----	----

		Male			
199	200	Male	30	137	83

#перегляд розміру набору даних

```
>>>customer_set.shape
```

```
(200, 5)
```

#перевірка повноти набору даних

```
>>>customer_set.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 5 columns):
 # Column Non-Null Count Dtype
---  -
 0 CustomerID 200 non-null int64
 1 Gender 200 non-null object
 2 Age 200 non-null int64
 3 Annual Income (k$) 200 non-null int64
 4 Spending Score (1-100) 200 non-null int64
dtypes: int64(4), object(1)
memory usage: 7.9+ KB
```

З отриманих результатів бачимо, що всі 200 рядків містять ненульові дані. Зробимо ще одну перевірку, яка підраховує кількість NaN значень

```
>>>customer_set.isnull().sum()
```

```
CustomerID 0
```

```
Gender 0
```

```
Age 0
```

```
Annual Income (k$) 0
```

```
Spending Score (1-100) 0
```

```
dtype: int64
```

Формування піднабору ознак для кластерного аналізу # Будуємо

DataFrame з 3 та 4 стовпців, які використовуватимемо, як ознаки

```
>>>x=customer_set.iloc[:, [3,4]].values
```

Створення моделі

Завантаження бібліотек та створення структури даних Для визначення оптимальної кількості кластерів будемо використовувати алгоритм k-середніх. Для цього завантажуюмо клас KMeans з модуля sklearn.cluster та створюємо список кластерів clalist.

```
>>>from sklearn.cluster import KMeans
```

```
clalist=[]
```

Обчислення оптимальної кількості кластерів

Основний код, який забезпечує створення об'єкта `kmeans` типу `KMeans`, з параметрами, що формують кількість кластерів та спосіб їх обчислення.

30

Метод об'єкта `kmeans.inertia_` дозволяє сформувати список кластерів у заданій кількості з використанням 10 центроїдів.

```
>>>for i in range(1,10):  
    kmeans = KMeans(n_clusters= i, init='k-means++', random_state=0)  
    kmeans.fit(x)  
    clalist.append(kmeans.inertia_)
```

Візуалізація результату роботи метода `Elbow` для отримання оптимальної кількості кластерів `k`.

```
>>>plt.plot(range(1,11), clalist)  
>>>plt.title('Метод Elbow')  
>>>plt.xlabel('Кількість кластерів')  
>>>plt.ylabel('clalist')  
>>>plt.show()
```




Рис. 1 Візуалізація методу `Elbow`

З рисунку 1 видно, що крива складається з трьох лінійних відрізків, останній з яких приблизно починається на рівні 5 по осі «Кількість кластерів». Тому збільшення діапазону пошуку призведе тільки до збільшення обчислень, але нічого не змінить. Тому ми вибрали `range(1, 11)`.

З вибраного діапазону, як правило, вибирають середнє значення. Тому зупиняємось на пошуку 5-ти кластерів.

Побудова моделі

Моделлю кластерного розподілу знову є об'єкт типу `KMeans`. Але у даному випадку ми формуємо модель з фіксованою кількістю

кластерів.

```
>>>kmeansmodel = KMeans(n_clusters= 5, init='k-means++', random_state=0)
>>>y_kmeans= kmeansmodel.fit_predict(x)
```

31

Оскільки для дана модель навчається без учителя, то для цього використовуємо відповідний метод `kmeansmodel.fit_predict(x)`, де `x` – це відповідний `DataFrame` ознак, який ми сформували раніше.

У випадку навчання з учителем ми повинні використовувати метод `kmeansmodel.fit_transform()`.

В результаті навчання без учителя ми отримали фінальну модель у об'єкті `y_kmeans`.

Подальше використання даної моделі залежить від того, які інструменти ми будемо для неї застосовувати.

Візуалізація моделі

Розглянемо графічне представлення отриманих кластерів з використанням бібліотеки `matplotlib`.

```
plt.scatter(x[y_kmeans == 0, 0], x[y_kmeans == 0, 1], s = 100, c = 'red', label = 'Cluster 1')
plt.scatter(x[y_kmeans == 1, 0], x[y_kmeans == 1, 1], s = 100, c = 'blue', label = 'Cluster 2')
plt.scatter(x[y_kmeans == 2, 0], x[y_kmeans == 2, 1], s = 100, c = 'green', label = 'Cluster 3')
plt.scatter(x[y_kmeans == 3, 0], x[y_kmeans == 3, 1], s = 100, c = 'cyan', label = 'Cluster 4')
plt.scatter(x[y_kmeans == 4, 0], x[y_kmeans == 4, 1], s = 100, c = 'magenta', label = 'Cluster 5')
plt.scatter(kmeansmodel.cluster_centers[:,0], kmeansmodel.cluster_centers[:, 1],s = 300, c='yellow',
label='Centroids')
plt.title('Кластери покупців')
plt.xlabel('Щорічний дохід ( тис. $)')
plt.ylabel('Бали (1-100)')
plt.legend()
plt.show()
```




Рис. 2 Візуалізація отриманих кластерів

Розглянемо приклад логічного пояснення такого поділу покупців на

кластери.

Кластер 1 – це найбільший за кількістю ознак кластер. Він описує покупців, які мають середній дохід та середні витрати. **Кластер 2** – цей кластер включає покупців, які мало заробляють, але забагато витрачають.

Кластер 3 – покупці з цього кластеру багато заробляють та багато витрачають. Тому торгова мережа повинна орієнтуватися саме на їх потреби.

Кластер 4 – покупці, які мало заробляють і мало витрачають.

Кластер 5 – покупці, які багато заробляють, але мало витрачають.

Зауваження

Матеріал даної лабораторної роботи підготовлено на основі матеріалів сайту <https://www.kaggle.com/>, який є одним з найпопулярніших сайтів для навчання у сфері DataScience. У своїй роботі ви можете використовувати будь-які матеріали з даного сайту за винятком набору даних, який використано в даній лабораторній роботі.

33

Завдання до лабораторної роботи № 5

1. Детально розглянути наведені теоретичні відомості до даної лабораторної роботи.
2. Ознайомитися з кодом, що наведений у Jupyter notebook `DD_lab5.ipynb`.
3. Завантажити з мережі Інтернет набір даних з розширенням `*.csv`, `*.txt`, `*.pdf` або `*.json` який орієнтований на вирішення задачі кластеризації методом k -середніх.

Для цього можна використати, наприклад, посилання

<https://data.world/datasets/clustering>

<http://cs.joensuu.fi/sipu/datasets/>

4. Вирішити задачу кластеризації, спираючись на приклад, який описаний у теоретичних відомостях та неведений у ноутбук `DD_lab5.ipynb`.
5. Результат виконання лабораторної роботи має містити

А) Звіт про виконання лабораторної роботи.

Звіт обов'язково має містити обґрунтоване пояснення прийнятих рішень щодо послідовності попередньої обробки даних, застосованого методу кластеризації, візуалізації.

Склад звіту:

- 25.Титул
- 26.Тема
- 27.Мета
- 28.Короткі теоретичні відомості
- 29.Опис роботи з ДОДАВАННЯМ скріншотів
- 30.Висновок.

Б) Пояснення причин та логіки розподілу даних на кластери.

В) Jupyter notebook файл з кодом та результатами обробки даних.

Г) Посилання на датасет у мережі Інтернет.

34

ЗМІСТ

	Назва лабораторної роботи ст
<i>Вступ.....</i>	<i>3</i>
<i>Лабораторна робота № 1. Індекссування, вибір, редагування набору даних.....</i>	<i>4</i>
<i>Лабораторна робота № 2. Підсумкові функції та відображення.....</i>	<i>7</i>
<i>Лабораторна робота № 3. Робота з пропущеними даними.....</i>	<i>20</i>
<i>Лабораторна робота №4. Розв'язування задачі лінійної регресії.....</i>	<i>23</i>
<i>Лабораторна робота №5. Розв'язування задачі кластеризації.....</i>	<i>28</i>

